PROVA DE APRENDIZAGEM DE MÁQUINA
Prof. Dr. Aydano Machado

Instruções para a prova:

Antes lembro que o Código de Honra vale para todas as atividades da disciplina:

Código de Honra

"Como membro da comunidade deste curso, não vou participar nem tolerar a desonestidade acadêmica".

A prova será individual, sem consulta e durante o horário da disciplina.
As respostas podem ser diretas, porém completas. Deixe em um nível de detalhe que eu entenda que você conhece cada passo necessário para implementar sua resposta.
Demonstre o que você entendeu o assunto abordado na questão sem a necessidade de ser prolixo. Pode citar e explicar com um algoritmo ou técnica que você aprendeu.

Questões

1. Descreva um dos algoritmos não-supervisionado: k-means, k-medoids ou dbscan?

K-means: A entrada consistem em uma base com N objetos e um número K de clusters e espera que a saída seja N objetos organizados em K clusters. Para cada cluster, seleciona um centróide aleatório para cada cluster, após isso, calcula um centróide de menor distância para cada ponto. e cada ponto pertence ao centróide mais próximo, após isso, posicionamos o centróide para uma posição média da posição de todos os pontos do cluster. Depois repetimos os dois últimos passos até obter uma posição ideal dos centróides.

2. Que algoritmo de *clustering* você usaria para cada uma das *databases* da figura abaixo? Explique o porquê da sua escolha.

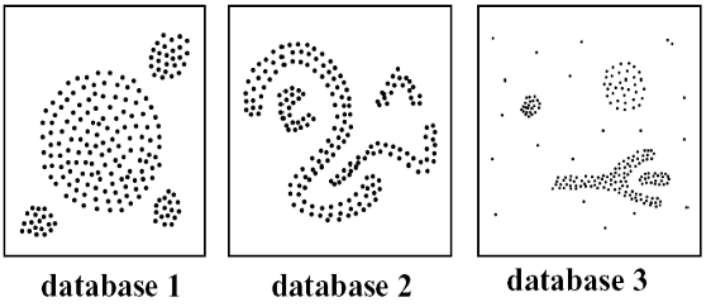


figure 1: Sample databases

Para o database 1: Podemos utilizar o K-means já que a base é um pouco mais comum, nesse caso, esse algoritmo pode ter um desempenho melhor já que a base de dados é mais comum.

Para o database 2: Podemos usar o DBScan, esse algoritmo baseado em densidade e trabalha com raio e densidade. Nessa base de dados, as distâncias de X e Y(relação a imagem), tem uma importância não linear, portanto é mais difícil de separar usando distâncias consideradas dos outros algoritmos.

Para o database 3: Podemos utilizar o K-medoids, pois esse algoritmo é mais adequado para bases com ruídos, ele funciona semelhante ao k-means, porém cada representante de cada cluster não será a média dos pontos, e sim um ponto pertencente ao cluster.

3. Descreva o algoritmo de mineração de regras de associação Apriori.

O algoritmo utiliza regras de associação e atribui a elas um suporte e uma confiança. As regras de associação são inferidas a partir de uma base de dados de maneira que A implica em B sendo A e B conjuntos de itens que estão presentes em transações na base de dados, para cada regra inferida é atribuído um suporte, que representa a porcentagem de transações da base de dados que contém os itens de A e B, e uma confiança, que representa dentre as transações que possuem os itens de A, a porcentagem de transações que possuem também os itens de B.