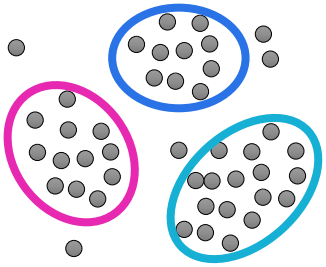



2

# Clusterização (Agrupamento)

**Agrupamento é o resultado da identificação de um conjunto finito de categorias (ou grupos - clusters) que contêm objetos similares.**

- **Grupos não são previamente definidos.**



3

# Exemplo: Clusterização (Agrupamento)

| Consumidor | Qtd.Tot. | Preço.Méd. |
|---|---|---|
| 1 | 2 | 1.700 |
| 2 | 10 | 1.800 |
| 3 | 2 | 100 |
| 4 | 3 | 2.000 |
| 5 | 12 | 2.100 |
| 6 | 3 | 200 |
| 7 | 4 | 2.300 |
| 8 | 11 | 2.040 |
| 9 | 3 | 150 |

4

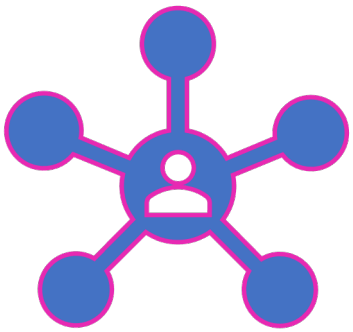
# Exemplo: Clusterização (Agrupamento)

| Grupo | Consumidor | Qtd.Tot. | Preço.Méd. |
|---|---|---|---|
| 1 | 1 | 2 | 1.700 |
| | 4 | 3 | 2.000 |
| | 7 | 4 | 2.300 |
| 2 | 2 | 10 | 1.800 |
| | 5 | 12 | 2.100 |
| | 8 | 11 | 2.040 |
| 3 | 3 | 2 | 100 |
| | 6 | 3 | 200 |
| | 9 | 3 | 150 |

5

## Algoritmos de agrupamento

- Organizam um conjunto de n objetos em (k) clusters (grupos) de objetos semelhantes.
- Características de um cluster?
- O número k de clusters?
- Ex.: k-means, k-medoids, dbscan.



6

# Entrada de dados

**Matriz de Dados**: contém os valores dos p atributos que caracterizam cada um dos n objetos.

$$\begin{bmatrix} x_{11} & \cdots & x_{1f} & \cdots & x_{1p} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{i1} & \cdots & x_{if} & \cdots & x_{ip} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_{n1} & \cdots & x_{nf} & \cdots & x_{np} \end{bmatrix}$$

7

# Entrada de dados

**Matriz de Dissimilaridade** (distâncias): contém as distâncias entre cada par de objetos.

- d(i,j) representa a dissimilaridade (diferença) entre os objetos i e j.

- d(i,j) ≥ 0 - d(i,j) = d(j,i) - d(i,i) = 0

$$\begin{bmatrix} 0 & & & & \\ d(2,1) & 0 & & & \\ d(3,1) & d(3,2) & 0 & & \\ \vdots & \vdots & \vdots & & \\ d(n,1) & d(n,2) & \ldots & \ldots & 0 \end{bmatrix}$$

8

## K-Means (MacQueen'67)

**Entrada**: base com n objetos e o número k de clusters.
**Saída**: n objetos organizados em k clusters.

→ escolher aleatoriamente k objetos como os centros (centróides) iniciais dos k clusters;

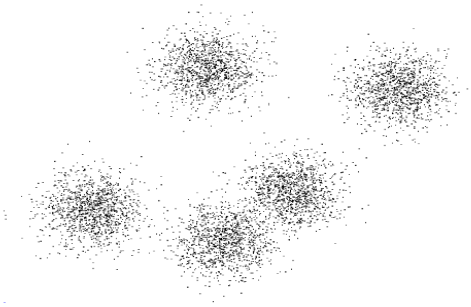
→ repetir

- (re)associar cada objeto ao cluster cujo centróide esteja mais perto;
- (re)calcular o centróide de cada cluster como sendo o valor médio dos objetos de cada cluster;

até que nenhuma alteração seja realizada.

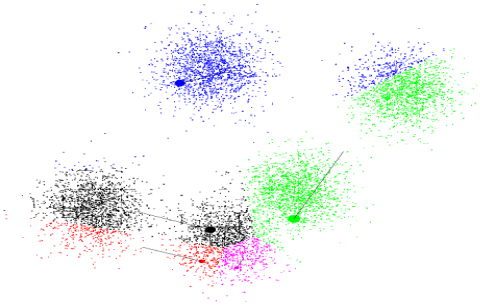
9

- Exemplo: Conjunto de 8.000 objetos em 2 dimensões.
  - k = 5



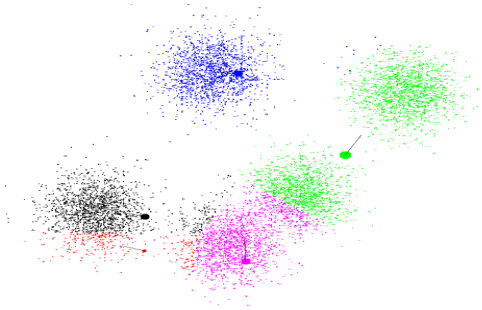
10

- Exemplo: 1ª iteração



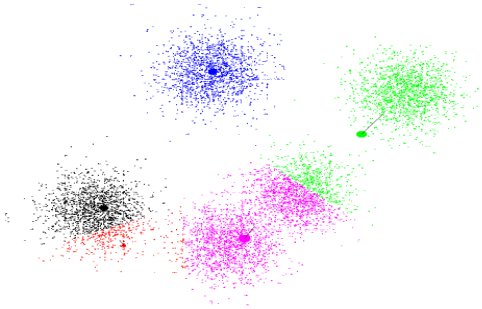
11

➡ Exemplo: 2ª iteração



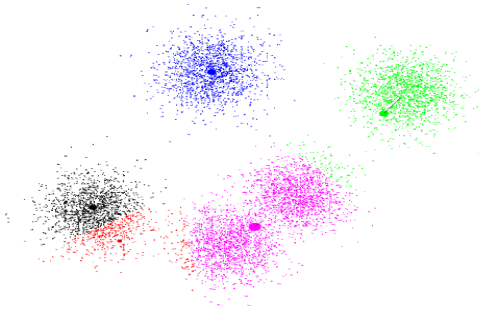
12

➡ Exemplo: 3ª iteração



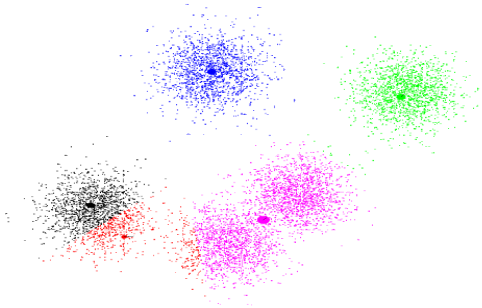
13

➡ Exemplo: 4ª iteração



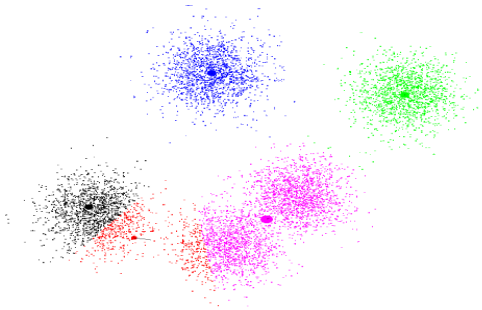
14

➡ Exemplo: 5ª iteração



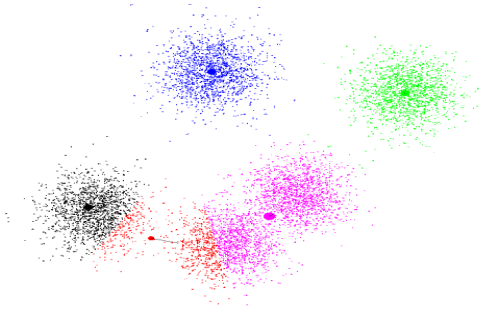
15

➡ Exemplo: 6ª iteração



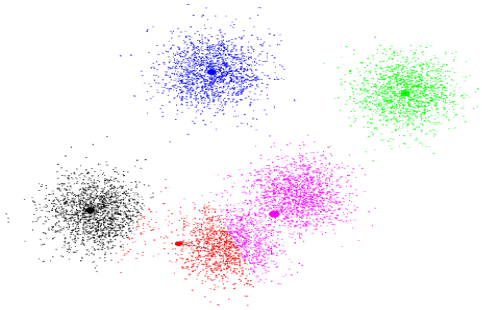
16

➡ Exemplo: 7ª iteração



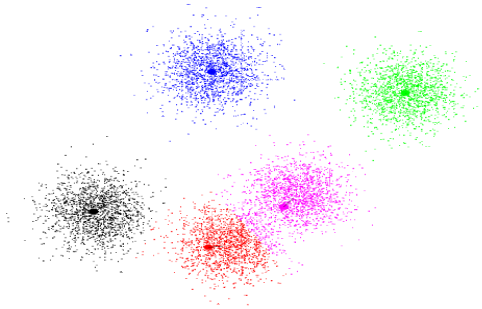
17

➡ Exemplo: 8ª iteração



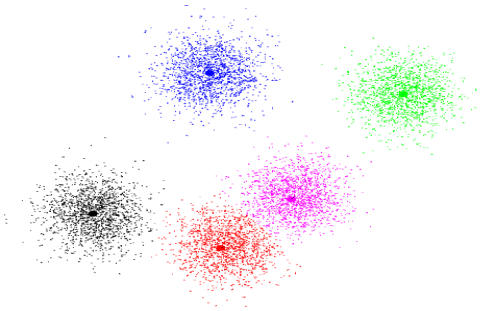
18

➡ Exemplo: 9ª iteração



19

Exemplo: 10ª iteração



20

# K-Means

- Classificado como um método de particionamento.
- Tenta encontrar k clusters não vazios tal que a soma das distâncias quadráticas entre os objetos e os centróides de seus respectivos clusters seja minimizada.
- Em geral, encontra um mínimo local.
- Em média, possui bom desempenho.
- Não adequado para identificar clusters de forma não convexa.
- Não trabalha bem com ruídos.

$$J = \sum_{i=1}^{k} \sum_{x \in Ci} \|x - m_i\|^2$$

21

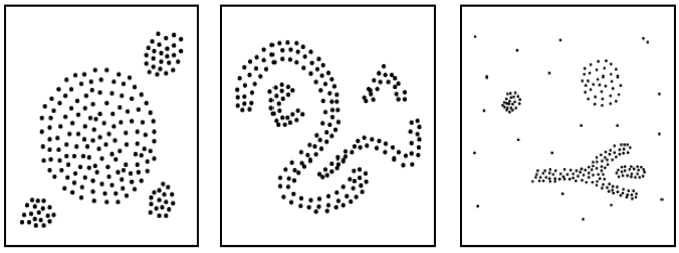



figure 1: Sample databases

22

# K-Medoids

(PAM - Partitioning Around Medoids, 1987)

- semelhante ao K-means, porém o representante de cada cluster não será a “média” dos pontos do cluster, mas sim um dos pontos pertencente ao cluster.

- a escolha dos medóides deve minimizar as distâncias entre os objetos e os medóides de seus respectivos clusters.

- o número de clusters (k) é um parâmetro de entrada,

- mais adequado para bases com ruídos.

23

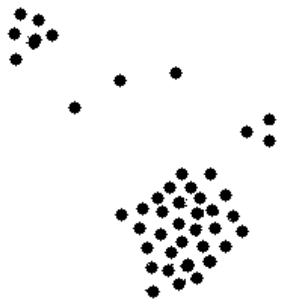
# DBSCAN

(Density-Based Spatial Clustering of Applications with Noise)

- método baseado em densidade,
- o número de clusters não é um parâmetro de entrada,
- bom para bases com ruídos,
- adequado para identificar clusters de formato arbitrário,
- trabalha com dois parâmetros: raio, densidade.

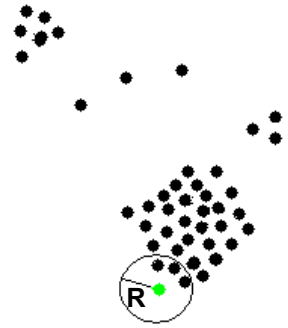
24

⟹ Exemplo: Conjunto de 44 objetos em 2 dimensões.
- **densidade** = 4 e um raio = **R**



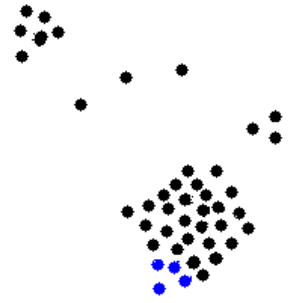
25

⇒ Exemplo: Conjunto de 44 objetos em 2 dimensões.
- **densidade** = 4 e um raio = **R**



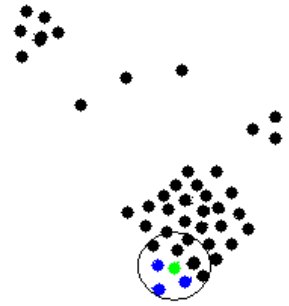

26

⇒ Exemplo: Conjunto de 44 objetos em 2 dimensões.
- **densidade** = 4 e um raio = **R**



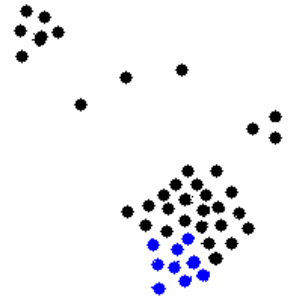
27

⇒ Exemplo: Conjunto de 44 objetos em 2 dimensões.
- **densidade** = 4 e um raio = **R**



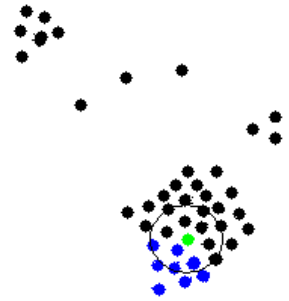
28

⇒ Exemplo: Conjunto de 44 objetos em 2 dimensões.
- **densidade** = 4 e um raio = **R**



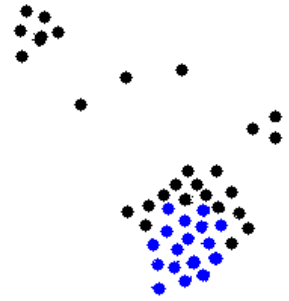
29

⇒ Exemplo: Conjunto de 44 objetos em 2 dimensões.
- **densidade** = 4 e um raio = **R**



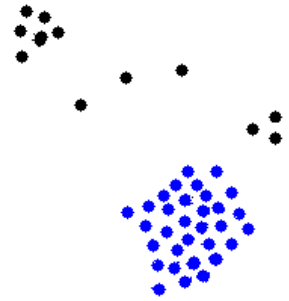
30

⇒ Exemplo: Conjunto de 44 objetos em 2 dimensões.
- **densidade** = 4 e um raio = **R**



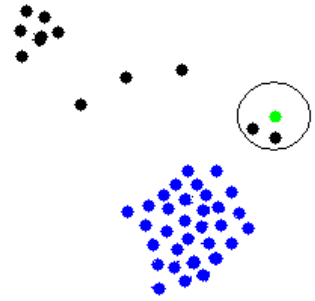
31

⇒ Exemplo: Conjunto de 44 objetos em 2 dimensões.
- **densidade** = 4 e um raio = **R**



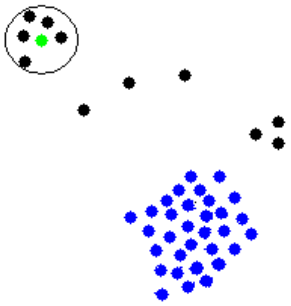
32

⇒ Exemplo: Conjunto de 44 objetos em 2 dimensões.
- **densidade** = 4 e um raio = **R**



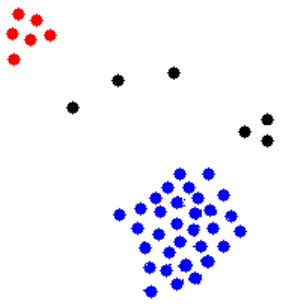
33

⇒ Exemplo: Conjunto de 44 objetos em 2 dimensões.
- **densidade** = 4 e um raio = **R**



34

⇒ Exemplo: Conjunto de 44 objetos em 2 dimensões.
- **densidade** = 4 e um raio = **R**



35

## Características Importantes

(de um algoritmo de clusterização)

- Escalabilidade,
- Aceitar diferentes tipos de dados,
- Identificar cluster de diferentes formatos,
- Poucos parâmetros de entrada,
- Tratamento de ruídos.

36

# Referências:


1. Data Mining: Concepts and Techniques. J.Han e M.Kamber, Morgan Kaufmann, segunda edição, 2006
2. Mineração de Dados: Algoritmos e Aplicações. Alexandre Plastino, Minicurso curso do ERBASE, 2010.


37


Computação
natural
linguagem
computacional
reconhecimento
fraude
Detecção
ReconhecimentoMarketing
padrões
Recuperação
sequenciais
ações
Bioinformática
Análise
Cinema
máquina
busca
robôs
Corte
opinião
Monitoramento
cérebro-computador
Processamento
médico
estratégia
sintáticos
Entendimento
Sistema
adaptativos
escrita
mineração
Visão
incluindo
Finanças
sentimento
Locomoção
Educação
matemática
Classificação
software
Análises
Economia
DNA
cartão
online
Interface
Anatomia
fala
Indústria
Saúde
crédito
Tradução
afetiva
heurística
meta-
virtual
Audiovisual
estrutural
objetos
Mecanismos
Mineração
Websites
informação
Percepção
Publicidade
quântica
saúde
Engenharia
Segurança
Jogos
mercado
sequências
Diagnósticos
Quimioinformática
recomendação

38