

2

Regras de associação

Padrão de relacionamento entre itens de dados do domínio da aplicação

- **{fralda} ⟹ {cerveja}**
- **{pão, manteiga} ⟹ {leite}**
- **{candidíase} ⟹ {pneumonia}**

3

Exemplo: regra de associação

Id-Transação (TID)	Itens Comprados
1	leite, pão, refrigerante
2	cerveja, carne
3	cerveja, fralda, leite, refrigerante
4	cerveja, fralda, leite, pão
5	fralda, leite, refrigerante

{fralda} ⇒ {cerveja}	confiança de 66%	(suporte médio)
{fralda} ⇒ {leite}	confiança de 100%	(suporte alto)
{leite} ⇒ {fralda}	confiança de 75%	(suporte alto)
{carne} ⇒ {cerveja}	confiança de 100%	(suporte baixo)

4

Regras de Associação:

- Regras de Associação (Transacionais)
- Regras de Associação Quantitativas (Relacionais ou Multidimensionais)
- Meta-Regras

5

Regras de Associação (Transacionais)

Uma regra de associação representa um padrão de relacionamento entre itens de dados de um domínio de aplicação que ocorre com uma determinada freqüência na base de dados.

{candidíase} $\Rightarrow$ {pneumonia}

{café, leite} $\Rightarrow$ {pão, manteiga, queijo}

A primeira regra indica, com um determinado grau de certeza, que se o paciente contraiu candidíase, então também teve pneumonia.

6

Regras de Associação (Transacionais)

Seja $I = \{i_1, i_2, ..., i_n\}$ o conjunto de itens do domínio da aplicação.

Uma regra de associação R definida sobre I é uma implicação da forma

$$\mathbf{X \Rightarrow Y}$$

onde $X \subset I$, $Y \subset I$, $X \neq \emptyset$, $Y \neq \emptyset$ e $X \cap Y = \emptyset$.

X é o antecedente da regra e Y é o conseqüente.

7

Regras de Associação

Regras de associação possuem índices que indicam sua relevância e a validade.

O fator de suporte de uma regra X ⇒ Y é definido pela porcentagem de transações que incluem todos os itens do conjunto X U Y.

→ Representa a fração das transações que satisfazem tanto o antecedente quanto o conseqüente da regra.

O suporte de uma regra tenta indicar sua relevância.

8

Regras de Associação

Seja R a regra X ⇒ Y.
Seja T o número de transações consideradas.
Seja T_{XUY} o número de transações que incluem os elementos de X U Y.

Suporte(R) = T_{XUY} / T

TID	Itens Comprados
101	leite, pão, suco
792	leite, suco
1130	leite, ovos
1735	pão, biscoito, café

Suporte({leite} ⇒ {suco}) = 2 / 4 = 50%
Suporte({suco} ⇒ {leite}) = 50%
Suporte({pão} ⇒ {suco}) = ___
Suporte({pão} ⇒ {ovos}) = ___
Suporte({pão,café} ⇒ {biscoito}) = ___

9

Regras de Associação

Seja X um conjunto de itens.
Seja T_X o número de transações que incluem os elementos de X.

Suporte(X) = T_X / T

TID	Itens Comprados	
101	leite, pão, suco	Suporte({leite}) = 3/4 = 75%
792	leite, suco	Suporte({leite,suco}) = 2 / 4 = 50%
1130	leite, ovos	Suporte({pão,suco}) = ___
1735	pão, biscoito, café	Suporte({pão,ovos}) = ___
		Suporte({pão,café,biscoito}) = ___

10

Regras de Associação

O fator de confiança de uma regra X ⇒ Y é definido pela porcentagem de transações que incluem os itens de Y dentre aquelas que incluem os itens de X.

→ Representa o grau de satisfatibilidade do conseqüente, em relação às transações que incluem o antecedente.

A confiança tenta indicar a validade da regra.

11

Regras de Associação

Seja R a regra $X \Rightarrow Y$.
Seja T_X o número de transações que incluem os elementos de X.
Seja T_{XUY} o número de transações que incluem os elementos de X U Y.

Confiança(R) = T_{XUY} / T_X

Id-T.	Itens Comprados	
101	leite, pão, suco	Confiança({leite} ⇒ {suco}) = 2 / 3 = 67%
792	leite, suco	Confiança({suco} ⇒ {leite}) = 2 / 2 = 100%
1130	leite, ovos	Confiança({pão} ⇒ {suco}) = ___
1735	pão, biscoito, café	Confiança({pão} ⇒ {ovos}) = ___
		Confiança({pão,café} ⇒ {biscoito}) = ___

12

Mineração de Regras de Associação

→ Entrada:

- Base de dados de transações;
- Suporte mínimo;
- Confiança mínima.

→ Saída:

- Todas as regras de associação que possuem suporte e confiança maiores ou iguais ao suporte e à confiança mínimos.

13

Exemplos de Regras Mineradas

- Entrada:
  - Base de Dados: POF-FGV (registro das compras mensais de 422 famílias cariocas em Junho de 1998)
  - SupMin = 3%, ConfMin = 60%
- Resultados:
  - Foram mineradas **8.469** regras de associação envolvendo 2 itens!
  - Exemplos:
    {Strogonoff de Frango (caixa)} ⇒ {Lasanha (caixa)}
    {Milho Verde em Conserva} ⇒ {Ervilhas em Conserva}
    {Kiwi} ⇒ {Feijão Preto}
    {Cenoura} ⇒ {Batata Inglesa}

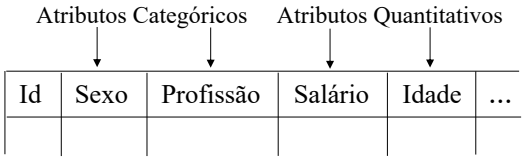
14

Regras de Associação Quantitativas
(Relacionais ou Multidimensionais)

Regras de associação quantitativas são utilizadas quando se deseja minerar padrões em bases de dados relacionais (formadas por atributos quantitativos e atributos categóricos).

Tabelas = Relações

Atributos = Dimensões



15

Regras de Associação Quantitativas

Exemplo (base de dados sobre a AIDS):

(Transmissão-Sexual = “Não”) ⇒ (Drogas = “Sim”)

→ Esta regra indica, com certo grau de certeza, que se o contágio não foi de natureza sexual, o paciente utiliza drogas.

Outra Notação (com Predicados):

Transmissão-Sexual(X,“Não”) ⇒ Drogas(X,“Sim”)

16

Regras de Associação Quantitativas

Seja D uma base de dados relacional.
Uma regra de associação quantitativa R definida sobre D é uma implicação da forma

$$\mathbf{X_1 \wedge X_2 \wedge ... \wedge X_n \Rightarrow Y_1 \wedge Y_2 \wedge ... \wedge Y_m}$$

onde $n \geq 1$, $m \geq 1$, X_i $(1 \leq i \leq n)$ e Y_j $(1 \leq j \leq m)$ são condições definidas sobre atributos distintos de D.

(Transmissão-Sexual = “Não”) ⇒ (Drogas = “Sim”)

Regras Híbridas:

(sexo=“M”) ∧ (20≤idade≤30) ∧ (compra inclui “fralda”) ⇒ (compra inclui “cerveja”)

17

Regras de Associação Quantitativas

- **Regras Multidimensionais**
  - Base do IBGE

(Escolaridade = "Analfabeto") ∧ (Sexo = "F") ∧ (Idade > 50) ⇒ (Ocupação = "Doméstica")

- **Regras Híbridas**
  - Base da FGV

(Cidade = "POA") ∧ (Membros = 1) ∧ (Produto = "cerveja) ⇒ (Produto = "salaminho")

18

Regras de Associação Quantitativas

→ Os conceitos de suporte e confiança se aplicam como nas regras convencionais.

• O fator de suporte representa a porcentagem de registros de D que satisfazem todas as condições X_i ($1 \leq i \leq n$) e Y_j ($1 \leq j \leq m$).

• O fator de confiança representa, dentre os registros de D que satisfazem as condições X_i ($1 \leq i \leq n$) (antecedente), a porcentagem dos registros que satisfazem Y_j ($1 \leq j \leq m$) (conseqüente).

19

Meta-Regras
(Mineração Baseada em Restrições)

- Permitem a especificação do tipo de regras que se deseja minerar.
- Podem funcionar como restrições definidas pelo usuário.
- Podem representar hipóteses a serem confirmadas

Meta-Regra:
$P1(X,Y) \wedge P2(X,Z) \Rightarrow buys(X,\text{“educational software”})$

Uma possível regra minerada:

$age(X,[30,39]) \wedge income(X,[41K,60K]) \Rightarrow buys(X,\text{“educational software”})$

20

Referências:

1. Data Mining: Concepts and Techniques. J.Han e M.Kamber, Morgan Kaufmann, segunda edição, 2006
2. Mineração de Dados: Algoritmos e Aplicações. Alexandre Plastino, Minicurso curso do ERBASE, 2010.

21