Medidas de Interesse

Exceções

1

▪1

Modelo Suporte/Confiança

- **Modelo Suporte/Confiança** (*Agrawal et al, 1993*):
  - Determinar todas as regras que tenham suporte e confiança maiores ou iguais aos valores mínimos especificados.
- **Problemas:**
  - O número de regras gerado costuma ser extremamente volumoso. Identificar as regras realmente úteis e interessantes torna-se uma tarefa difícil.
  - O modelo gera regras redundantes, ilusórias ou até mesmo contraditórias.

2

▪2

Modelo Suporte/Confiança

- **Entrada**:
  - Base de Dados: POF-FGV (registro das compras mensais de 422 famílias cariocas em Junho de 1998)
  - SupMin = 3%
  - ConfMin = 60%
- **Resultados**:
  - Foram mineradas **8.469** regras de associação envolvendo 2 itens!

3

▪3

Modelo Suporte/Confiança

- **Grupo I**: antecedente e conseqüente muito populares.

R: Cenoura ⇒ Batata Inglesa s: 70,38% c: 91,38%
Sup(Cenoura) = 77,01%
Sup(Batata Inglesa) = 81,75%

- **Grupo II**: antecedente pouco freqüente e conseqüente muito freqüente (**obs:** *80% das regras mineradas*).

R: Filé de Viola ⇒ Açúcar Refinado s: 7,58% c: 86,49%
Sup(Filé de Viola) = 8,77%
Sup(Açúcar Refinado) = 86,49%

- **Grupo III**: antecedente e conseqüente pouco freqüentes.

R: Strogonoff de Frango (caixa) ⇒ Lasanha (caixa) s: 3,32% c: 77,78%
Sup(Strogonoff) = 4,27%
Sup(Lasanha) = 14,45 %

4

▪4

Dependência entre Itens

Id	Regra de Associação	Sup_A	Sup_B	Sup	Conf
R1	Filé de Viola ⇒ Açúcar Refinado	8,77%	86,49%	7,58%	86,49%

- A confiança da regra indica que 86,49% dos clientes que compram filé de viola, também compram açúcar refinado.
- A probabilidade de qualquer cliente comprar açúcar refinado é de 86.49%.
- Os dois produtos são **independentes**.

  Sup(B) = Conf(A ⇒ B)

5

▪5

Dependência entre Itens

Id	Regra de Associação	Sup_A	Sup_B	Sup	Conf
R2	Banana Nanica ⇒ Banana Prata	12,09%	76,07%	7,35%	60,78%

- A confiança da regra indica que 60,78% dos clientes que compram banana nanica, também compram banana prata.
- A probabilidade de qualquer cliente comprar banana prata é de 76.07%. Portanto clientes que compram banana nanica têm menor chance de comprar banana prata.
- Os dois produtos possuem **dependência negativa**

  Sup(B) > Conf(A ⇒ B)

6

▪6

Dependência entre Itens

Id	Regra de Associação	Sup_A	Sup_B	Sup	Conf
R3	Milho Verde em Conserva ⇒ Ervilhas em Conserva	32,94%	37,91%	27,01%	82,01%

- A confiança da regra indica que 82,01% dos clientes que compram milho verde, também compram ervilhas.
- A probabilidade de qualquer cliente comprar ervilhas é de 37.91%. Portanto clientes que compram milho verde têm uma chance muito maior de comprar ervilhas.
- Os dois produtos possuem **dependência positiva**.

  Sup(B) < Conf(A ⇒ B)

7

▪7

Medidas Objetivas

- **Lift(A ⇒ B)** : indica o quanto mais freqüente torna-se B quando A ocorre.

  Lift(A ⇒ B) = Conf (A ⇒ B) ÷ Sup(B)

Ex 1: R: Filé de Viola ⇒ Açúcar Refinado
Lift(R) = 0,8649 ÷ 0,8649 = **1**

Ex 2: R: Banana Nanica ⇒ Banana Prata
Lift(R) = 0,6078 ÷ 0,7607 = **0,80**

Ex 3: R: Milho Verde em Conserva ⇒ Ervilhas em Conserva
Lift(R) = 0,8201 ÷ 0,3791 = **2,21**

8

▪8

Exceções

- **Proposta:**
  - Mineração de exceções negativas e positivas.
  - Usuários podem explorar um conjunto de regras de associação, descobrindo se elas tornam-se significativamente **mais fortes** ou **mais fracas** em algum subconjunto da base de dados.

9

▪9

Exceções – Base da AIDS

- **Fonte**: Ministério da Saúde
- Casos de AIDS diagnosticados no Brasil entre 1980 e 2001.
- 172.563 tuplas e 10 atributos. (pacientes com idade superior a 13 anos).
- **Entrada:**
  - *R*: (*Transmissão Sexual = "Não"*) ⇒ (*Drogas = "Sim"*)
    Sup = 13,05%, Conf = 88,09%
  - *A* = {Sexo, Idade, Região}
- **Saída**:
  - 41 exceções negativas e 5 exceções positivas.

10

▪10

Exceções – Base da AIDS

- **Exceção Negativa:**

(*Transmissão Sexual = "Não"*) $\overset{-s}{\Rightarrow}$ (*Drogas = "Sim"*) [(Sexo = "F"),
(Região = "Norte")]

11

▪11

Exceções – Base da AIDS

Microsoft Access - [F_NORTE_DROGAS : Consulta seleção]

Arquivo Editar Exibir Inserir Formatar Registros Ferramentas Janela Ajuda

SEXO	REGIAO	UF	IDADE	TRANSMISSAO_SEXUAL	TRANSFUSAO	DROGAS
F	NORTE	PA	35-39 ANOS	NAO	SIM	NAO
F	NORTE	RR	25-29 ANOS	NAO	SIM	NAO
F	NORTE	PA	ACIMA DE 50 ANOS	NAO	SIM	NAO
F	NORTE	PA	40-49 ANOS	NAO	NAO	SIM
F	NORTE	PA	40-49 ANOS	NAO	SIM	NAO
F	NORTE	PA	35-39 ANOS	NAO	SIM	NAO
F	NORTE	RO	20-24 ANOS	NAO	SIM	NAO
F	NORTE	RO	30-34 ANOS	NAO	SIM	NAO
F	NORTE	AM	ACIMA DE 50 ANOS	NAO	SIM	NAO
F	NORTE	AP	25-29 ANOS	NAO	NAO	SIM
F	NORTE	RO	25-29 ANOS	NAO	SIM	NAO
F	NORTE	RO	20-24 ANOS	NAO	SIM	NAO
F	NORTE	PA	25-29 ANOS	NAO	SIM	NAO
F	NORTE	PA	40-49 ANOS	NAO	SIM	NAO
F	NORTE	TO	35-39 ANOS	NAO	NAO	SIM
F	NORTE	PA	35-39 ANOS	NAO	SIM	NAO
F	NORTE	PA	30-34 ANOS	NAO	NAO	SIM
F	NORTE	PA	20-24 ANOS	NAO	NAO	SIM

12

▪12

Exceções – Base do Censo

- **Fonte**: UCI Repository of Machine Learning Databases
- Censo da cidade de Washington, ano de 1990
- 48.842 tuplas e 14 atributos.
- **Entrada:**
  - *R*: (*IncomeClass* = "*>50K*")
    Sup = 24,08%
  - *A* = {Education, Gender, HoursPerWeek, Age}.
- **Saída:**
  - 20 exceções positivas.

13

▪13

Exceções – Base do Censo

- **Exceções Positivas:**

$\overset{+s}{\Rightarrow}$ (*IncomeClass* = "*>50K*") [(Education = "Doctorate")]
MF^+ = 0,6702

$\overset{+s}{\Rightarrow}$ (*IncomeClass* = "*>50K*") [(Education = "Masters")]
MF^+ = 0,5682

$\overset{+s}{\Rightarrow}$ (*IncomeClass* = "*>50K*") [(HoursPerWeek = "56-60")]
MF^+ = 0,4474

$\overset{+s}{\Rightarrow}$ (*IncomeClass* = "*>50K*") [(HoursPerWeek = "51-55")]
MF^+ = 0,4428

$\overset{+s}{\Rightarrow}$ (*IncomeClass* = "*>50K*") [(Age = "46-50")]
MF^+ = 0,3961

$\overset{+s}{\Rightarrow}$ (*IncomeClass* = "*>50K*") [(Age = "51-55")]
MF^+ = 0,3934

14

▪14

Exceções – Regras Híbridas

- **Base de Dados da POF (1999)**
  - **Regras Híbridas Positivas:**

    {*cerveja em lata*} $\overset{+s+c}{\Rightarrow}$ {*salame e salaminho*} [(Membros=1)]

    {*neston*} $\overset{+s+c}{\Rightarrow}$ {*farinha láctea*} [(Membros=5)]

    {*leite longa vida*} $\overset{+s+c}{\Rightarrow}$ {*pão francês*} [(Cidade="Porto Alegre")]

  - **Regras Híbridas Negativas:**

    {*neston*} $\overset{-s-c}{\Rightarrow}$ {*farinha láctea*} [(Membros=2)]

    {*leite longa vida*} $\overset{-s-c}{\Rightarrow}$ {*pão francês*} [(Renda="2,5 a 4,99 Sal. Min.")]

    {*leite longa vida*} $\overset{-s-c}{\Rightarrow}$ {*pão francês*} [(Cidade="Recife")]

15

▪15